

2a.)

Zu zeigen: $\langle p^{k+1}, p^k \rangle = 0$ für exakte Linienansuche

$$h(\alpha^k) = f(x^k + \alpha^k p^k)$$

$$\frac{d}{d\alpha} h = \nabla f(\underbrace{x^k + \alpha^k p^k}_{= x^{k+1}})^T \cdot p^k = 0 = \nabla f(x^{k+1})^T \cdot p^k = (p^{k+1})^T \cdot p^k = \langle p^{k+1}, p^k \rangle_2 = 0$$

Bedingung für die exakte Linienansuche

2b.)

Vorüberlegung: Für $x, y \in \mathbb{R}^n$ und $A \in \mathbb{R}^{n \times n}$ symmetrisch positiv definit, definiert $\langle x, y \rangle_A := x^T A y$ ein Skalarprodukt.

Beweis: 1.) Linearität: $\forall \lambda \in \mathbb{R} \forall x, y, z \in \mathbb{R}^n: \langle \lambda x + y, z \rangle = \lambda \langle x, z \rangle + \langle y, z \rangle$

$$\langle \lambda x + y, z \rangle_A = (\lambda x + y)^T A z = \lambda x^T A z + y^T A z = \lambda \langle x, z \rangle_A + \langle y, z \rangle_A$$

2.) Symmetrie: $\forall x, y \in \mathbb{R}^n: \langle x, y \rangle = \langle y, x \rangle$

$$\langle x, y \rangle_A = x^T A y = (x^T A y)^T = y^T A^T x = y^T A x = \langle y, x \rangle_A$$

H. Voraussetzung ist A symmetrisch

3.) Definitheit: $\forall x \in \mathbb{R}^n: \langle x, x \rangle \geq 0 \wedge (\langle x, x \rangle = 0 \Leftrightarrow x = 0)$

$$3a.) \langle x, x \rangle \geq 0: \langle x, x \rangle_A = x^T A x \geq 0 \quad \forall x \in \mathbb{R} \setminus \{0\}$$

A positiv definit

$$3b.) \langle x, x \rangle = 0 \Leftrightarrow x = 0 \quad \text{also: } x^T A x = 0 \Leftrightarrow x = 0$$

" $\Rightarrow$ " A ist positiv definit $\Leftrightarrow 0$ ist nicht Eigenwert von A

$$\Leftrightarrow \text{Kern}(A) = \{0\} \Rightarrow (x^T A x = 0 \Rightarrow x = 0)$$

$$\text{" $\Leftarrow$ " } x = 0 \in \mathbb{R}^n \Rightarrow x^T A x = 0 \cdot A \cdot 0 = 0$$

Das Skalarprodukt $\langle x, y \rangle_A$ induziert eine Vektornorm:

$$\|x\|_A := \sqrt{x^T A x} = \sqrt{\langle x, x \rangle_A}$$

Mit der Cauchy-Schwarz-Ungleichung gilt daher:

$$\langle x, y \rangle_A \leq \|x\|_A \cdot \|y\|_A$$

Für $\|x\|_A = \|y\|_A = 1$ folgt damit:

$$\langle x, y \rangle_A \leq 1$$

Skalarprodukt und Norm sind mit $A \in \mathbb{R}^{n \times n}$ und $x, y \in \mathbb{R}^n$ definiert. Auf den Betrag von das Skalarprodukt in der CSU kann daher verzichtet werden.

zu zeigen: $p^k := \frac{A^{-1} \nabla f(x^k)}{\|A^{-1} \nabla f(x^k)\|_A}$ minimiert $\frac{d}{d\alpha} f(x^k + \alpha p) |_{\alpha=0}$

unter allen Richtungen $p \in \mathbb{R}^n$ mit $\|p\|_A = 1$.

$$\begin{aligned} \frac{d}{d\alpha} f(x^k + \alpha p) \Big|_{\alpha=0} &= \langle p, \nabla f(x^k) \rangle_2 = \langle \nabla f(x^k), p \rangle_2 \\ &= -\|A^{-1} \nabla f(x^k)\|_A \cdot \langle A p^k, p \rangle_2 \\ &= -\|A^{-1} \nabla f(x^k)\|_A \cdot (p^k)^T A^T p \\ &= -\|A^{-1} \nabla f(x^k)\|_A \cdot (p^k)^T A p \\ &= -\|A^{-1} \nabla f(x^k)\|_A \cdot \langle p^k, p \rangle_A \end{aligned}$$

$$\text{mit } \langle p^k, p \rangle_A \leq \|p^k\|_A \cdot \|p\|_A = 1$$

$$\uparrow \text{Gleichheit f\"ur } p^k = p, \quad \langle p^k, p^k \rangle_A = \|p^k\|_A^2 = 1^2 = 1$$

Damit folgt:

$$\frac{d}{d\alpha} f(x^k + \alpha p) \Big|_{\alpha=0} = -\|A^{-1} \nabla f(x^k)\|_A \cdot \langle p^k, p \rangle_A \geq -\|A^{-1} \nabla f(x^k)\|_A$$

$\Rightarrow$ Unter allen Richtungen $p \in \mathbb{R}^n$ mit $\|p\|_A = 1$ wird $\frac{d}{d\alpha} f(x^k + \alpha p) \Big|_{\alpha=0}$ durch $p = p^k$ minimiert.

$\uparrow$ Gleichheit f\"ur $p^k = p$

③

a)

i)

Sei x^k konvergent mit Ordnung $p > 1$, d.h. $\limsup_{k \rightarrow \infty} \frac{\|e^{k+1}\|}{\|e^k\|^p} = c < \infty$

Dann gilt: $\frac{\|e^{k+1}\|}{\|e^k\|} \leq \underbrace{c \cdot \|e^k\|^{p-1}}_{=: p}$

Für $k \rightarrow \infty$ ist $p < 1$, da $\|e^k\|^{p-1} \rightarrow 0$ konvergiert.

Damit konvergiert (x^k) superlinear.

ii) Es gilt (x^k) konvergiert superlinear, d.h. $\limsup_{k \rightarrow \infty} \frac{\|e^{k+1}\|}{\|e^k\|} = 0$.

Wähle $p := 0$, dann gilt $\limsup_{k \rightarrow \infty} \frac{\|e^{k+1}\|}{\|e^k\|} = p < 1$ und damit:

(x^k) konvergiert linear.

iii) Es gilt (x^k) konvergiert linear, d.h. $\limsup_{k \rightarrow \infty} \frac{\|e^{k+1}\|}{\|e^k\|} = p < 1$

Damit gilt $\frac{\|e^{k+1}\|}{\|e^k\|} = p^2$, und damit (Induktion) $\frac{\|e^{k+1}\|}{\|e^0\|} = p^k \xrightarrow{k \rightarrow \infty} 0$, da $p < 1$ ist.

Da also $\limsup_{k \rightarrow \infty} \|e^k\| = 0$ gilt, konvergiert (x^k) also sublinear.

b)

$$f(x_1, x_2) = ax_1^2 + bx_2^2, \quad a, b > 0.$$

$$\nabla f(x_1, x_2) = (2ax_1, 2bx_2)$$

$$\nabla^2 f(x_1, x_2) = \begin{pmatrix} 2a & 0 \\ 0 & 2b \end{pmatrix}$$

$\nabla^2 f(x_1, x_2)$ hat die EW $\lambda_1 = 2a$, $\lambda_2 = 2b$, weswegen

$$K(\nabla^2 f(x)) = \begin{cases} \frac{a}{b} & \text{für } a > b \\ \frac{b}{a} & \text{für } b > a \end{cases}$$

(1) Obere Schranke von $\|e_f^{k+1}\| := \|f(x^{k+1}) - f(x^*)\|$ ist $\| \frac{a-b}{(a+b)^2} \| \cdot \|e_f^k\|$, da gilt:

$$\begin{aligned} \|e_f^{k+1}\| &= \|f(x^{k+1}) - f(x^*)\| = \left\| \left(1 - \frac{((g^k)^T g^k)^2}{\underbrace{g^{kT} A g^k g^{kT} A^{-1} g^k}_{\geq \frac{4 \lambda_{\min} \lambda_{\max}}{(\lambda_{\min} + \lambda_{\max})^2}}} \right) (f(x^k) - f(x^*)) \right\| \stackrel{\text{Kontrovich}}{\leq} \left\| 1 - \frac{4ab}{(a+b)^2} \right\| \cdot \|f(x^k) - f(x^*)\| \\ &= \left\| \frac{a-b}{(a+b)^2} \right\| \cdot \|f(x^k) - f(x^*)\| = \underbrace{\left\| \frac{a-b}{(a+b)^2} \right\|}_{< 1, \text{ da } a, b > 0} \cdot \|e_f^k\| \end{aligned}$$

(2) Obere Schranke für die Konvergenzrate von $\|e^k\|$ ist $\underbrace{\frac{|a-b|}{|a+b|}}_{< 1, \text{ da } a, b > 0} \|e^k\|_A$, denn:
Sei $\|e^k\|_A := \|x^k - x^*\|_A$. Dann ist nach Satz 2.28

$$\|e^{k+1}\| \leq \rho(A) \|e^k\|_A = \frac{\lambda_{\max} - \lambda_{\min}}{\lambda_{\max} + \lambda_{\min}} \|e^k\|_A = \frac{|a-b|}{|a+b|} \|e^k\|_A.$$

Vorüberlegung:

$$K(\nabla^2 f(x)) \rightarrow \infty \quad \text{g.d.w.}$$

1. $\lambda_{\min} \rightarrow 0$ (oder)
2. $\lambda_{\max} \rightarrow \infty$ (oder)
3. $\lambda_{\min} \rightarrow 0$ und $\lambda_{\max} \rightarrow \infty$.

Mit den Abschätzungen (1), (2) folgt dann:

$$\|e_f^{k+1}\| \leq \underbrace{\frac{(a-b)^2}{(a+b)^2}}_{\rightarrow 1 \text{ für } K(\nabla^2 f(x)) \rightarrow \infty} \|e_f^k\| \rightarrow \|e_f^k\|$$

und

$$\|e^{k+1}\| \leq \underbrace{\frac{|a-b|}{|a+b|}}_{\rightarrow 1 \text{ für } K(\nabla^2 f(x)) \rightarrow \infty} \|e^k\| \rightarrow \|e^k\|$$

D.h. die Fehler bleiben für sehr schlechte

Konditionierung der Hesse-Matrix gleich, wodurch das Verfahren

nur noch äußerst schlecht bzw. gar nicht mehr konvergiert.

3c.) Im Satz über die Konvergenz des Gradientenabstiegsverfahrens wird A als symmetrisch, positiv definit vorausgesetzt.

Im Folgenden wird dies ebenfalls angenommen.

1.) Zu zeigen: $\sqrt{\lambda_{\min}} \cdot \|x\|_2 \leq \|x\|_A \leq \sqrt{\lambda_{\max}} \cdot \|x\|_2$

A symmetrisch $\Rightarrow A$ ist diagonalisierbar $\Leftrightarrow$ Eigenvektoren v_i von A bilden eine Basis des $\mathbb{R}^n$

$\forall x \in \mathbb{R}^n$ existiert also eine Darstellung in der Basis, die aus

Eigenvektoren von A besteht $\Rightarrow x = \sum_{i=1}^n \delta_i \cdot v_i \quad \delta_i \in \mathbb{R}$

Damit folgt:

λ_i sei Eigenwert zum Eigenvektor v_i

j -te Komponente von x : $(x)_j = \sum_{i=1}^n \mathcal{J}_i \cdot (v_i)_j$

$$(Ax)_j = A \cdot \sum_{i=1}^n \mathcal{J}_i \cdot (v_i)_j = \sum_{i=1}^n \mathcal{J}_i \cdot A \cdot v_i$$

$$Ax = \sum_{i=1}^n \mathcal{J}_i \cdot A \cdot v_i = \sum_{i=1}^n \mathcal{J}_i \cdot \lambda_i \cdot v_i$$

$$(Ax)_j = \sum_{i=1}^n \mathcal{J}_i \cdot \lambda_i \cdot (v_i)_j$$

$$\Rightarrow x^T Ax = \sum_{j=1}^n \left(\sum_{i=1}^n \mathcal{J}_i \cdot (v_i)_j \right) \cdot \left(\sum_{i=1}^n \mathcal{J}_i \cdot (v_i)_j \cdot \lambda_i \right)$$

$$\leq \lambda_{\max} \sum_{j=1}^n \underbrace{\left(\sum_{i=1}^n \mathcal{J}_i \cdot (v_i)_j \right)}_{=x_j} \cdot \underbrace{\left(\sum_{i=1}^n \mathcal{J}_i \cdot (v_i)_j \right)}_{=x_j} = \lambda_{\max} x^T \cdot x$$

Durch $\lambda_{\min}$ kann $x^T Ax$ ebenso nach unten abgeschätzt werden.

$$\text{Also: } \lambda_{\min} \cdot x^T \cdot x \leq x^T Ax \leq \lambda_{\max} \cdot x^T \cdot x$$

Aus strengen Monotonie (Wachstum) der Wurzelfunktion folgt:

$$\sqrt{\lambda_{\min}} \cdot \sqrt{x^T \cdot x} \leq \sqrt{x^T Ax} \leq \sqrt{\lambda_{\max}} \cdot \sqrt{x^T \cdot x}$$

$$\Leftrightarrow \sqrt{\lambda_{\min}} \cdot \|x\|_2 \leq \|x\|_A \leq \sqrt{\lambda_{\max}} \cdot \|x\|_2$$

Mit Satz 2.2.8 gilt: $\|x^k - x^*\|_A \leq \rho(A) \cdot \|x^{k-1} - x^*\|_A$ bzw.

$\|x^{k+1} - x^*\|_A \leq \rho(A) \cdot \|x^k - x^*\|_A$. Mit der obigen Abschätzung folgt:

$$\sqrt{\lambda_{\min}} \cdot \|x^k - x^*\|_2 \leq \|x^k - x^*\|_A \leq \rho(A) \cdot \|x^{k-1} - x^*\|_A$$

$\|x^{k-1} - x^*\|_A$ kann ebenfalls abgeschätzt werden (Satz 2.2.8):

$$\cancel{\|x^{k-1} - x^*\|_A \leq \sqrt{\lambda_{\max}} \cdot \|x^{k-1} - x^*\|_2} \quad \|x^{k-1} - x^*\|_A \leq \rho(A) \cdot \|x^{k-2} - x^*\|_A$$

$$\Leftrightarrow \rho(A) \cdot \|x^{k-1} - x^*\|_A \leq \rho(A)^2 \cdot \|x^{k-2} - x^*\|_A$$

Durch wiederholtes Abschätzen ^(k-mal) nach oben folgt:

$$\rho(A) \cdot \|x^{k-1} - x^*\|_A \leq \rho(A)^2 \cdot \|x^{k-2} - x^*\|_A \leq \dots \leq \rho(A)^k \cdot \|x^0 - x^*\|_A$$

Es folgt:

$$\sqrt{\lambda_{\min}} \cdot \|x^k - x^*\|_2 \leq \rho(A) \cdot \|x^{k-1} - x^*\|_1 \leq \rho(A)^k \cdot \|x^0 - x^*\|_1 \leq \rho(A)^k \cdot \sqrt{\lambda_{\max}} \cdot \|x^0 - x^*\|_2$$

Abo:

$$\sqrt{\lambda_{\min}} \cdot \|x^k - x^*\|_2 \leq \rho(A)^k \cdot \|x^0 - x^*\|_2 \cdot \sqrt{\lambda_{\max}}$$

$\Leftrightarrow$

$$\|x^k - x^*\|_2 \leq \frac{\sqrt{\lambda_{\max}}}{\sqrt{\lambda_{\min}}} \cdot \rho(A)^k \cdot \|x^0 - x^*\|_2$$

$\Leftrightarrow$

$$\|x^k - x^*\|_2 \leq \sqrt{\kappa(A)} \cdot \rho(A)^k \cdot \|x^0 - x^*\|_2 \quad \square$$